

# Yapay Sinir Ağları ile Uçuşlardaki Gecikmelerin Öngörülmesi: Bir Havalimanı Çalışması

## Predicting Flight Delays with Artificial Neural Networks: Case Study of an Airport

Engin Demir  
Bilgisayar Mühendisliği Bölümü  
Çankaya Üniversitesi  
Ankara, Türkiye  
engindemir@cankaya.edu.tr

Vahap Burhan Demir  
Bilgi İşlem Dairesi Başkanlığı  
Adalet Bakanlığı  
Ankara, Türkiye  
vahapburhan@gmail.com

**Özetçe—** Hava taşımacılığı, ulaşım sistemleri içerisinde önemli bir yere sahip olup uçuşların planlanan zamanlarda seferlerini gerçekleştirmesi, yolcuların konforu ve işletme maliyetlerin kontrol edilebilirliğini sağlamak için gereklidir. Uçuş gecikmelerinin hava durumu, hava trafiğinde yaşanan yoğunluk, kaza veya kapanan uçuş pistleri, uçaklar arasındaki mesafenin arttırılmasına sebep olabilecek koşullar ve yer hizmetlerinde yaşanabilecek işletmeden kaynaklı gecikmeler gibi çok çeşitli nedenleri bulunmaktadır. Bu çalışmada havalimanında bulunan çeşitli algılayıcılardan toparlanan veriler ve uçuşla ilgili bilgiler kullanılarak yapay sinir ağları ile uçuşlardaki kalkış gecikmelerini tahmin eden bir yapay sinir ağı modeli geliştirilmesi hedeflenmiştir.

**Anahtar Kelimeler —**Uçuş gecikme tahmini, sınıflandırma, yapay sinir ağları, öznitelik sıralama.

**Abstract—**Air transportation has an important place among transportation systems and it is indispensable for the flights to perform their voyages in scheduled time in order to ensure the comfort of passengers and controllability of operational costs. There are several reasons for flight delays like weather conditions, excessive intensity in air traffic, accidents or closed airfields, conditions that will lead to an increase in distances between planes and operational delays in ground services. In this study, using the data collected from the sensors located in the airport and the information about the flight, the goal is develop a machine learning model to estimate departure delays of flights using artificial neural networks.

**Keywords —**Flight delay estimation, classification, artificial neural networks, feature ranking.

### I. GİRİŞ

Amerika Birleşik Devletleri Ulaştırma Bürosu tarafından yayınlanan bilgiye göre 2015 yılındaki uçuşların %19.63'ü gecikme ya da iptallerden dolayı zamanında gerçekleşmemiştir. Planlanmış uçuşlarda yaşanan gecikmeler havayolu firmalarına ciddi maliyetler yaratmakta, yolcuların memnuniyetlerini azalttığından havayolu firmasının marka değerini olumsuz yönde etkilemektedir. Bu sebeple birçok

ülke, vatandaşlarının yaşanması muhtemel bu gecikmelerden doğan zararlarını karşılamak için caydırıcı yasalar çıkarmışlar ve parasal cezai yaptırımlar uygulamaktadırlar. Ancak bu caydırıcı yaptırımların varlığı uçuşlardaki gecikmelerin sıklıkla yaşanmasına engel olamamaktadır. Uluslararası Hava Taşımacılığı Birliği (IATA) tarafından ticari uçuşlardaki kalkışlar için gecikme kodları standartlaştırılmış ve önceki çalışmalarda uçuş gecikmelerinin başlıca nedenleri uygunsuz hava koşulları, hava trafiği yoğunluğu, havalimanı kapasitesi (yolcu, pist ve köprü sayısı vb..) , teknik ve mekanik sorunlar, ulusal havacılık sistemleri ve güvenlik olarak sıralanmıştır.

Uçuşlar için geliştirilecek gecikme tahmin sistemlerinin kullanılmasıyla gecikmeden kaynaklı maliyetlerin azaltılması mümkün olmakta ve firmalar milyar dolarlık tasarruf edebilmektedirler. Özellikle öğrenme özelliği bulunan uyarı sistemleri ile gecikmeler önceden tahmin edilebilir. Gecikme tahmin sonuçları yolcu, havalimanı ve havayolu firması ile anlık paylaşılarak gerekli önlem ve planlamalar uçuş öncesinde alınabilir. Bu sayede risk planlamasına da önemli katkılar olabilir. Federal Havacılık Kurulu'nun (FAA) uçuş planlamaları ve gecikmelerden kaynaklanan maliyetleri azaltmak için çalışmalar bulunmaktadır [8]. Zonglei vd. denetimli öğrenme algoritmaları kullanılarak büyük ölçekli uçuş gecikmelerinde bir alarm sistemi tasarlanmış ve aciliyet durumuna göre farklı renklerde alarmlar üretilmiştir [10]. Choi vd. ABD'deki 2005-2015 yılları arasında uçuş verileri (kalkış varış havalimanları ve zamanları) ile hava verilerini kullanarak gözetimli öğrenme yöntemlerinden karar ağaçları, rastgele orman, AdaBoost ve  $k$  en yakın komşu algoritmaları ile uçuşları zamanında ve gecikmeli olarak ikili sınıflamıştır ve en iyi rastgele orman yöntemi ile % 83.40 başarımla elde etmişlerdir [3]. Belcastro vd. dünya genelince ortalama uçuşların %20 sinin 15 dakika ile geciktiği ve milyarlarca dolar maliyeti olduğundan yola çıkarak Choi vd. çalışmasındaki gibi uçuş verileri (kalkış varış havalimanları ve zamanları) ile hava verilerini kullanarak 15 dakika altı ve 60 dakika altındaki gecikmeleri sınıflandırmışlar ve yaklaşık %74 ve %85 başarımla elde etmişlerdir [2].

Rebollo ve Balakrishnan [9] hava trafiğindeki gecikmeleri modellemek için zaman ve uzay boyutunda ulaşım ağındaki gecikmeleri açıklayıcı değişkenler olarak kullanmış ve rastgele orman algoritması ile 2-24 saat aralığındaki gecikmeleri tahmin etmiştir. ABD ulusal hava sisteminin 2007-2008 verilerini kullanarak kalkış-varış noktaları için sınıflandırma ve regresyon testleri gerçekleştirmiş, deneysel çalışmalar sonucunda ortalama hatası 2-24 saatlik dilim için 100 kalkış-varış verisinde 19.1 ile 27.4 dakika aralığında bulunmuştur. Pekiştirmeli öğrenme yaklaşımı ile uçakların taksi kalkış zamanlarının öğrenilmesi ve gecikmelerin belirlenmesi [1], yapay sinir ağları kullanılarak JFK havalimanına inişlerdeki gecikmelerin modellenmesi [6] uçuşlardaki gecikmelerin farklı yönlerden incelenmesi açısından örnek teşkil etmektedir.

Bu çalışmada hava taşımacılığı sektöründe önemli bir sorun olan uçuşlardaki kalkış gecikmelerinin tahmin edilmesi üzerine yapay sinir ağları ile denetimli bir öğrenme modeli geliştirilmiştir. Bu modelin öğretilmesi için literatürdeki benzer çalışmaların çoğundan farklı olarak hava trafiği ağı değil belirli bir havalimanı seçilmiştir. Öğrenme modeli için kullanılan özellikler önceki çalışmalardan farklı olarak uçak bilgilerini de içermektedir.

## II. MATERYAL VE YÖNTEM


### A. Veri Kümesi

Veri kümesinde 2014 yılı içerisinde Esenboğa Uluslararası Havalimanı'na yapılan seferlerin iniş ve kalkış bilgileri ile havalimanındaki algılayıcılardan toplanan meteorolojik ölçümler yer almaktadır. İniş kaydı olan uçuşlar için kalkış havalimanları ve kalkış koşulları yer almadığından değerlendirmeye alınmamıştır.

Esenboğa Havalimanından alınan verilerde 2014 yılı içerisindeki toplam 45.479 kalkış gerçekleşmiştir. Veri kümesi içerisinde boş alan içeren kayıtlar çıkartıldığında 39.892 kalkış verisi kullanılmıştır. Bu kapsamda planlanan kalkış zamanında veya öncesinde gerçekleşen uçuşlar “Zamanında”, planlanan zamandan sonra gerçekleşen uçuşlar ise “Geciken” ismiyle etiketlenmiştir. Geciken uçuşlar için maksimum gecikme süresi yaklaşık 21 saattir.

Şekil 1’de kalkışı geciken uçuşların sayısı ve günlük gecikme sürelerinin ortalaması gösterilmiştir. Şekil incelendiğinde kalkışlardaki gecikmelerin sayısı ile gecikme süresi arasında doğru bir orantı olmadığı görülmektedir. Örneğin geciken uçuş sayısının yıllık ortalama çok düşük olduğu sabah 09:00 saatleri civarında gecikme süresinin ortalama 1 saati, yine aynı şekilde saat 12:00 civarında geciken uçuş sayısı ortalama çok düşük iken gecikme süresinin 2 saati bulduğu görülmüştür. Benzer bir şekilde akşam 21:00-24:00 arası yıllık ortalama geciken uçuş sayısı 1-50 arasında değişirken ortalama gecikme süresinin 6 saate kadar çıktığı görülmektedir. Sanılanın aksine mesai giriş ve çıkış saat aralıklarında yaşanan yoğun trafikten dolayı uçuşlarda belirgin bir ortalama gecikme gözlemlenmemiştir.

Meteorolojik veriler Meteoroloji Genel Müdürlüğü’nün Esenboğa İstasyonu’ndan toplanmıştır. Her gün ilk ölçüm 00:50’de yapılmış ve ölçümler 1 saat aralıklarla tekrarlanmıştır.



Şekil. 1.Gün içerisindeki her uçuş saati için yıllık ortalama gecikme süresi

### B. Öznitelikler

Elde edilen ham veriden aşağıdaki 12 özellik elde edilmiştir.

#### Uçuş/uçak öznitelikleri:

- Uçaktaki yolcu koltuk sayısı: 0 ile 505 arasında değişmektedir. Örneğin nakliye, kısa mesafe jet uçağı, eğitim uçaklarında yolcu koltuk sayısı 0 olarak belirtilmektedir.
- Uçağın ağırlığı (Tonaj): 0 ile 447 ton arasında değişmektedir. Örneğin özel uçaklarda uçağın ağırlığı 0 olarak belirtilmiştir.
- Uçuş amacı: Yolcu, kargo, teknik, genel, askeri ve eğitim kategorilerinde incelenmiştir.

#### Meteorolojik öznitelikler:

- Basınç (Hektopaskal): Basınç değerleri 891.7 ile 919 arasında değişmektedir.
- QNH (Qualified Natural Horizon) Basınç: QNH basınç değerleri 999.5 ile 1,030 arasında değişmektedir.
- Bulut Kapalılığı (Okta): Dikey görüşün ifade edilmesi açısından çok önemli bir tanımlama olup, 8 eşit parçaya bölündüğü varsayılan semanın, ne kadarının bulutlar tarafından kaplandığının ifadesidir. 9 değeri de görüşün tamamen kapalı olduğunu belirtmektedir. Ölçüm birimi 0 ile 9 arasındaki tam sayılardır.
- Bulut Yüksekliği (feet): Bulutların görülüp izlenebildiği yüksekliğin yerden olan dikey mesafesi bulut taban yüksekliği olarak adlandırılmaktadır. Bulut yüksekliğinin değerleri 100 ile 4,000 arasında değişmektedir.
- Görüş Mesafesi (metre): Gündüzleri aydınlatılmamış, geceleri ise aydınlatılmış uygun boyutları olan bir cismin, atmosferik koşullara bağlı olarak görülüp algılanabileceği en uzak mesafe olarak tanımlanmaktadır. Görüş mesafesinin değerleri 100 ile 4.000 arasında değişmektedir.
- Nispi Nem: Havanın içerisinde çözülmüş halde bulunan su buharı miktarının, havayı doyuma noktasına getirmek için gerekli maksimum su miktarına oranıdır. 0 ile 100 arasındaki yüzdelik değer olarak ölçülür. Nem değerleri 9 ile 100 arasında değişmektedir.
- Rüzgâr Hızı: Hareket vektörünün büyüklüğü, skaler bir niceliktir. Ölçüm değerleri 0 ile 28 arasında değişmektedir.

- Rüzgâr Yönü: Rüzgârın yeryüzüne paralel hareket doğrultusunu ifade eder. Rüzgâr yönü genellikle ana ve ara yönlerde veya açısal azimut olarak ifade edilir. Rüzgâr yönü değerleri 0 ile 8 arasında değişmektedir.
- Sıcaklık (Santigrat): Sıcaklık değerleri - 9.3 ile 37.1 arasında değişmektedir.

Kullanılan özniteliklerin değerleri normalleştirme yapılarak belirli bir aralığa indirgenmiştir. Çalışmamızda pozitif olan tüm öznitelikleri 0 ve 1 arasına, negatif olan öznitelikleri de -1 ve 1 arasına indirmek için minimum-maksimum normalleştirme yöntemi kullanılmıştır.

### C. Yapay Sinir Ağı Modeli

Çalışma kapsamında denetimli öğrenme modeli olarak yapay sinir ağı (YSA) kullanılmıştır. YSA, yapay nöronların düğüm ve ağırlıklı yönlü kenarların nöron girişleri ve nöron çıkışları arasındaki bağlantı olduğu ağırlıklı yönlü çizge olarak da düşünülebilir. Bağlantı mimarilerine bağlı olarak YSA farklı yapılara sahip olabilir. YSA girdi ve çıktı katmanlarından oluşabileceği gibi ayrıca bir ya da birden fazla ara katmana da sahip olabilir.

YSA düğümlerinde aktivasyon fonksiyonu olarak genellikle sigmoid ya da tanjant fonksiyonu kullanılmakta olup, bu çalışmada normalizasyon sonucunda -1 ve 1 aralığında değerler elde edildiğinden tanjant fonksiyonu kullanılmıştır. Tek katmanlı YSA modelleri karmaşık modellemeler için yetersiz kalacağından çok katmanlı geri beslemeli YSA yani katmanların çıktılarını önceki katmanlara geri besleme döngülerinin bulunduğu yapı tercih edilmiştir. Öğrenme modeli ikili sınıflandırma için geliştirilmiş olup, her öznitelik YSA'ya girdi olarak verilip, çıktı olarak zamanında ya da geciken sınıflandırması yapılmıştır.

Giriş ve çıkış katmanındaki nöron sayısı probleme göre belirlenirken, gizli katmandaki nöron sayısını veren herhangi bir analitik yöntem yoktur [4]. Gizli katmandaki nöron sayısının belirlenmesinde üst sınır olarak Karsoliya tarafında belirtilen öneriler kullanılmıştır [5]. Buna göre tanımlanan 3 farklı model ve ara katmanlardaki nöron sayıları belirlenmiştir: 1. Model (15-10-10), 2. Model (20-10-10), ve 3. Model (25-10-10).

Eğitim yöntemi olarak çeşitli yaklaşımlar mevcut olmakla birlikte en uygun eğitim fonksiyonunun belirlenmesi için YSA modeli MATLAB kullanılarak derlenmiş ve 14 farklı eğitim fonksiyonu ile yapılan ön testlerde Levenberg-Marquardt (LM) algoritması ve ortalama karesel hata (MSE) kullanılarak yapılan testlerde daha iyi sonuç verdiği tespit edildiğinden deneysel çalışmalarda bu model tercih edilmiştir.

### D. Öznitelik Seçimi

Özellik seçimi, veri kümesinden, uygun bir öznitelik altkütmesi elde edilmesiyle hem doğru sınıflandırma oranı, hem de ölçeklenebilirlik bakımından daha iyi bir sınıflandırma modeli elde edilmesini sağlayan bir yöntemdir. Literatürde kullanılan çok sayıda özellik seçimi algoritması vardır. Bu çalışmada filtre özellik seçimi algoritması kullanılmıştır. Filtre yöntemleri özellikleri seçmek için, kümeleme algoritması kullanmadan verinin bazı asıl özelliklerini seçmektedir. Filtre yöntemlerinin özellik arama yöntemi ve özellik seçim kriteri

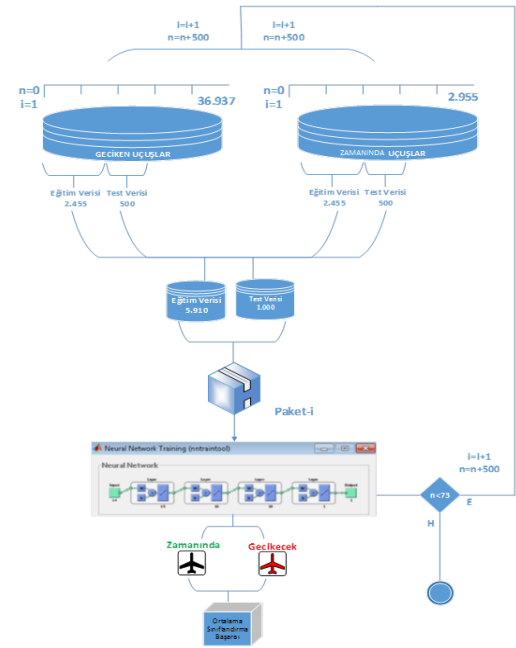
olmak üzere iki temel bileşeni vardır [7]. Çalışmamızda tahmini Mahalanobis mesafeleri toplamı ve Öklid mesafelerinin karelerinin toplamı özellik seçimi yöntemleri kullanılmıştır.

## III. DENEYSEL SONUÇLAR

TABLO I. ÖZNİTELİK SEÇİMİ SIRALAMASI

Sıra	Mahalanobis	Öklid
1	Uçuş amacı	Bulut yüksekliği
2	Koltuk sayısı	Rüzgâr yönü
3	Tonaj	Bulut kapalılığı
4	Rüzgâr hızı	Sıcaklık
5	Sıcaklık	Nem
6	Bulut yüksekliği	Uçuş amacı
7	Bulut kapalılığı	Koltuk sayısı
8	Görünürlük	Görünürlük
9	Rüzgâr yönü	Rüzgâr hızı
10	Nem	Tonaj
11	Basınç	Basınç
12	QNH-basınç	QNH-basınç

Tablo I'da özellik seçimi sonucunda elde edilen özniteliklerin sıralaması gösterilmiştir. 2. sütunda görüldüğü üzere Mahalanobis mesafeleri toplamı ile öznitelikler sıralanınca uçak ve uçuş ile ilgili özellikler üst sıralarda yer almaktadır.



Şekil 2. Veri kümesindeki dengesiz dağılım problemi için geliştirilen kayan pencere yöntemi

Kullanılan veri kümesinin karakteristiği gereği, geciken kalkışların oranı tüm verinin yaklaşık % 93'ünü oluşturduğu halde, % 80 eğitim, % 20 test verisi olacak şekilde çapraz doğrulama uygulayarak uçuş gecikmesi için modellenen YSA eğitildiğinde, sınıflandırmadaki başarı oranının ortalama %92.73 olduğu gözlemlenmiştir. Ancak verilerin mevcut dağılımı ile ağır öğrenme değil, belli bir tekrarlardan sonra aşırı yüklenme durumu yüksek bir olasılıktır. Bu problemi aşmak için eğitim ve test verisinin her yineleme için eşit

oranda YSA'ya verilmesi için Şekil 2'de gösterilen kayan pencere yöntemi geliştirilmiştir. Bu yaklaşımla veri kümesinde oransal olarak daha az bulunan zamanındaki uçuşlar temel alınarak eğitim ve test verilerinin eşit oranda dağıtılması sağlanmıştır.

TABLO II. YSA TEST VE ÖĞRENME VERİ DAĞILIMLARI VE BAŞARIM SONUÇLARI

			1.Model	2.Model	3.Model
Veri dağılımı (Penceredeki)	Eğitim	Zamanında	2,455	2,455	2,455
		Geciken	2,455	2,455	2,455
	Test	Zamanında	500	500	500
		Geciken	500	500	500
YSA	Katmanlardaki nöron sayısı		15-10-10	20-10-10	25-10-10
	Pencere sayısı		73	73	73
	Öznitelikler (Mahalanobis özellik seçme sırasına göre ilk 10)		Uçuş amacı – Koltuk Sayısı – Tona – Rüzgâr hızı – Sıcaklık – Bulut yüksekliği – Bulut kapallılığı – Görünürlük – Rüzgâr yönü – Nem		
Doğru sınıflandırma yüzdesi (%)	En yüksek		99.60	99.10	98.50
	En düşük		67.40	56.40	67.60
	Ortalama		93.69	93.16	92.53

Tablo II'de gösterildiği gibi eğitim verisi eşit oranda dağıtıldığında başarımları ortalama en düşük % 92.53 olduğundan sınıflandırmada gecikmelerin fazla sayıda örneklenmesinin önemi olmadığı anlaşılmıştır. Test edilen 3 model arasında başarımları orani olarak ciddi farklar olmadığı ancak 1. Modelin daha iyi başarımları gösterdiği anlaşılmaktadır.

TABLO III. DAKİKA BAZLI DOĞRU SINIFLANDIRMA ORANLARI (%)

Gecikme Süreleri(dk.)							
$\leq 1$	$\leq 5$	$\leq 10$	$\leq 30$	$\leq 60$	$\leq 120$	$\leq 180$	$\leq 360$
96.34	94.58	95.06	92.43	96.86	89.84	92.52	83.21

TABLO IV. ARALIK BAZLI DOĞRU SINIFLANDIRMA ORANLARI (%)

Gecikme Süreleri(dk.)							
$\leq 1$	$1 < \leq 5$	$5 < \leq 10$	$10 < \leq 30$	$30 < \leq 60$	$60 < \leq 120$	$120 < \leq 180$	$180 < \leq 360$
91.85	87.96	90.02	86.39	92.92	81.18	83.72	74.61

Bunun yanı sıra YSA'ya sadece hava durumu ve uçak/uçuş bilgileri öznitelikleri verilerek başarımları oranı ölçülmüştür. Sonuçlara göre sadece hava durumu öznitelikleri verilerek elde edilen başarımları oranı ortalama %71.14, sadece uçak/uçuş bilgileri verilerek elde edilen başarımları oranı ise ortalama %82.38 olarak bulunmuştur. Elde edilen bu sonuçlar uçuş gecikme tahmini için tasarlanan YSA'da veri kümesi olarak sadece uçak/uçuş bilgilerinin kullanmanın sadece meteorolojik verilerin kullanılmasına göre daha başarılı sonuç verdiğini göstermektedir. Öznitelik seçimi yaklaşımlarının kullanılması ile belirlenen özelliklerin sıralanması ve seçimi sonucunda

başarımları oranlarının en yüksek %99.60 çıktığı gözlemlenmiştir. Bu nedenle gecikme belirlemeleri için ilgili özellik türlerinin birlikte kullanılması önerilmektedir.

Uçuş gecikme tahmini için tasarlanan YSA'nın her dakika bazlı aralık için sınıflandırmadaki ortalama başarımları sonucu Tablo III ve IV'te gösterilmiştir. Verideki uçuşların gecikme sürelerinin farklı dağılımları göstermesine karşın YSA modelinin değişik gecikme süreleri için de yakın başarımları oranları gösterdiği gözlemlenmiştir.

#### IV. SONUÇLAR

Havalimanındaki algılayıcılardan toplanan hava durumu verilerinin uçak ve uçuş bilgileri ile zenginleştirilmesi sonucu elde edilen öznitelikler kullanılarak denetimli bir öğrenme modeli olan geri beslemeli bir Yapay Sinir Ağları ile gecikme sınıflandırma modeli tasarlanmış ve gerçekleştirilmiştir. Denetimli öğrenme sonucunda oluşturulan üç katmanlı Yapay Sinir Ağı modeli ile uçuşlardaki kalkış gecikmelerin yüksek doğruluk oranı ile sınıflandırılabilirliğini gösterilmiştir. Gecikme süresinin sınırlandırıldığı farklı aralıklarda da yüksek doğruluk ile sınıflandırma yapılabildiği tespit edilmiştir. Elde edilen doğruluk oranlarının artırılması için en güncel sinirsel ağ modelleri ya da aşırı öğrenme makinesi tabanlı yöntemler ileriki çalışmalarda incelenecektir. Çalışma kapsamında sadece yapay sinir ağları ile kavram doğrulaması yapılmış olmakla birlikte ileriki çalışmada farklı sınıflandırma yöntemleri ile performans karşılaştırması gerçekleştirilecektir.

#### Kaynaklar

- [1] P. Balakrishna, R. Ganesan, ve L. Sherry, "Accuracy of reinforcement learning algorithms for predicting aircraft taxi-out times: A case-study of Tampa Bay departures", Transportation Research Part C: Emerging Technologies, c. 18, sayı 6, ss. 950–962, 2010.
- [2] L. Belcastro, F. Marozzo, D. Talia, ve P. Trunfio, "Using Scalable Data Mining for Predicting Flight Delays", ACM Trans. Intell. Syst. Technol., c. 8, sayı 1, s. 5:1–5:20, 2016.
- [3] S. Choi, Y. J. Kim, S. Briceno, ve D. Mavris, "Prediction of weather-induced airline delays based on machine learning algorithms", içinde 2016 IEEE/AIAA 35th Digital Avionics Systems Conference (DASC), 2016, ss. 1–6.
- [4] M. Efe ve O. Kaynak, Yapay Sinir Ağları ve Uygulamaları. Boğaziçi Üniversitesi Yayınları, 2000.
- [5] S. Karsoliya, "Approximating Number of Hidden layer neurons in Multiple Hidden Layer BPNN Architecture", International Journal of Engineering Trends and Technology, c. 3, sayı 6, ss. 714–717, 2012.
- [6] S. Khanmohammadi, S. Tutun, ve Y. Kucuk, "A New Multilevel Input Layer Artificial Neural Network for Predicting Flight Delays at JFK Airport", Procedia Computer Science, c. 95, ss. 237–244, 2016.
- [7] H. Liu ve M. Hiroshi, Computational Methods of Feature Selection. Chapman and Hall/CRC Press, 2007.
- [8] S. A. Morrison ve C. Winston, "The effect of FAA expenditures on air travel delays", Journal of Urban Economics, c. 63, sayı 2, ss. 669–678, 2008.
- [9] J. J. Rebollo ve H. Balakrishnan, "Characterization and prediction of air traffic delays", Transportation Research Part C: Emerging Technologies, c. 44, ss. 231–241, 2014.
- [10] L. Zonglei, W. Jiandong, ve Z. Guansheng, "A New Method to Alarm Large Scale of Flights Delay Based on Machine Learning", içinde 2008 International Symposium on Knowledge Acquisition and Modeling, 2008, ss. 589–592.